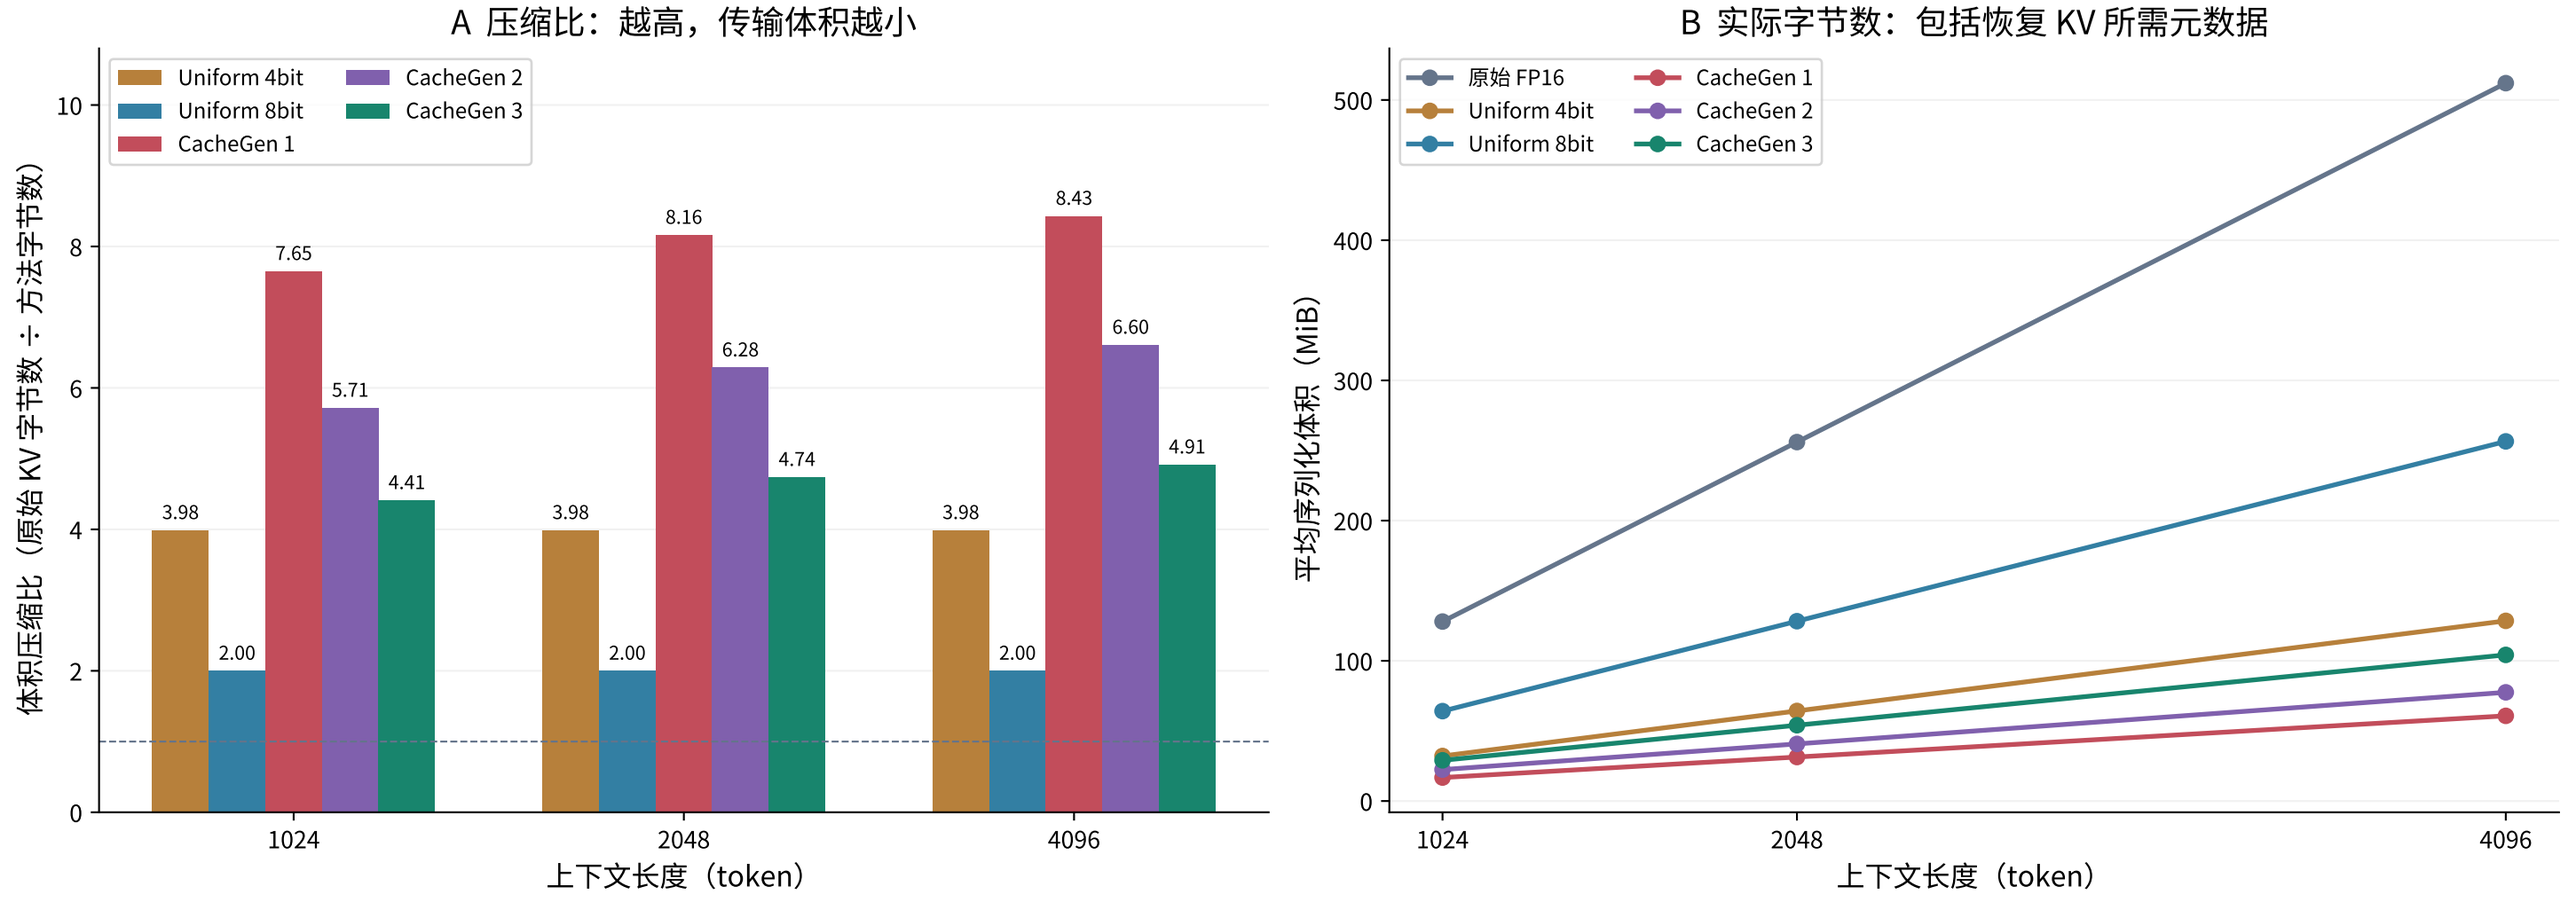图 1｜压缩收益：10 条源文本 × 3 种长度；所有方法共享 8bit 模型权重