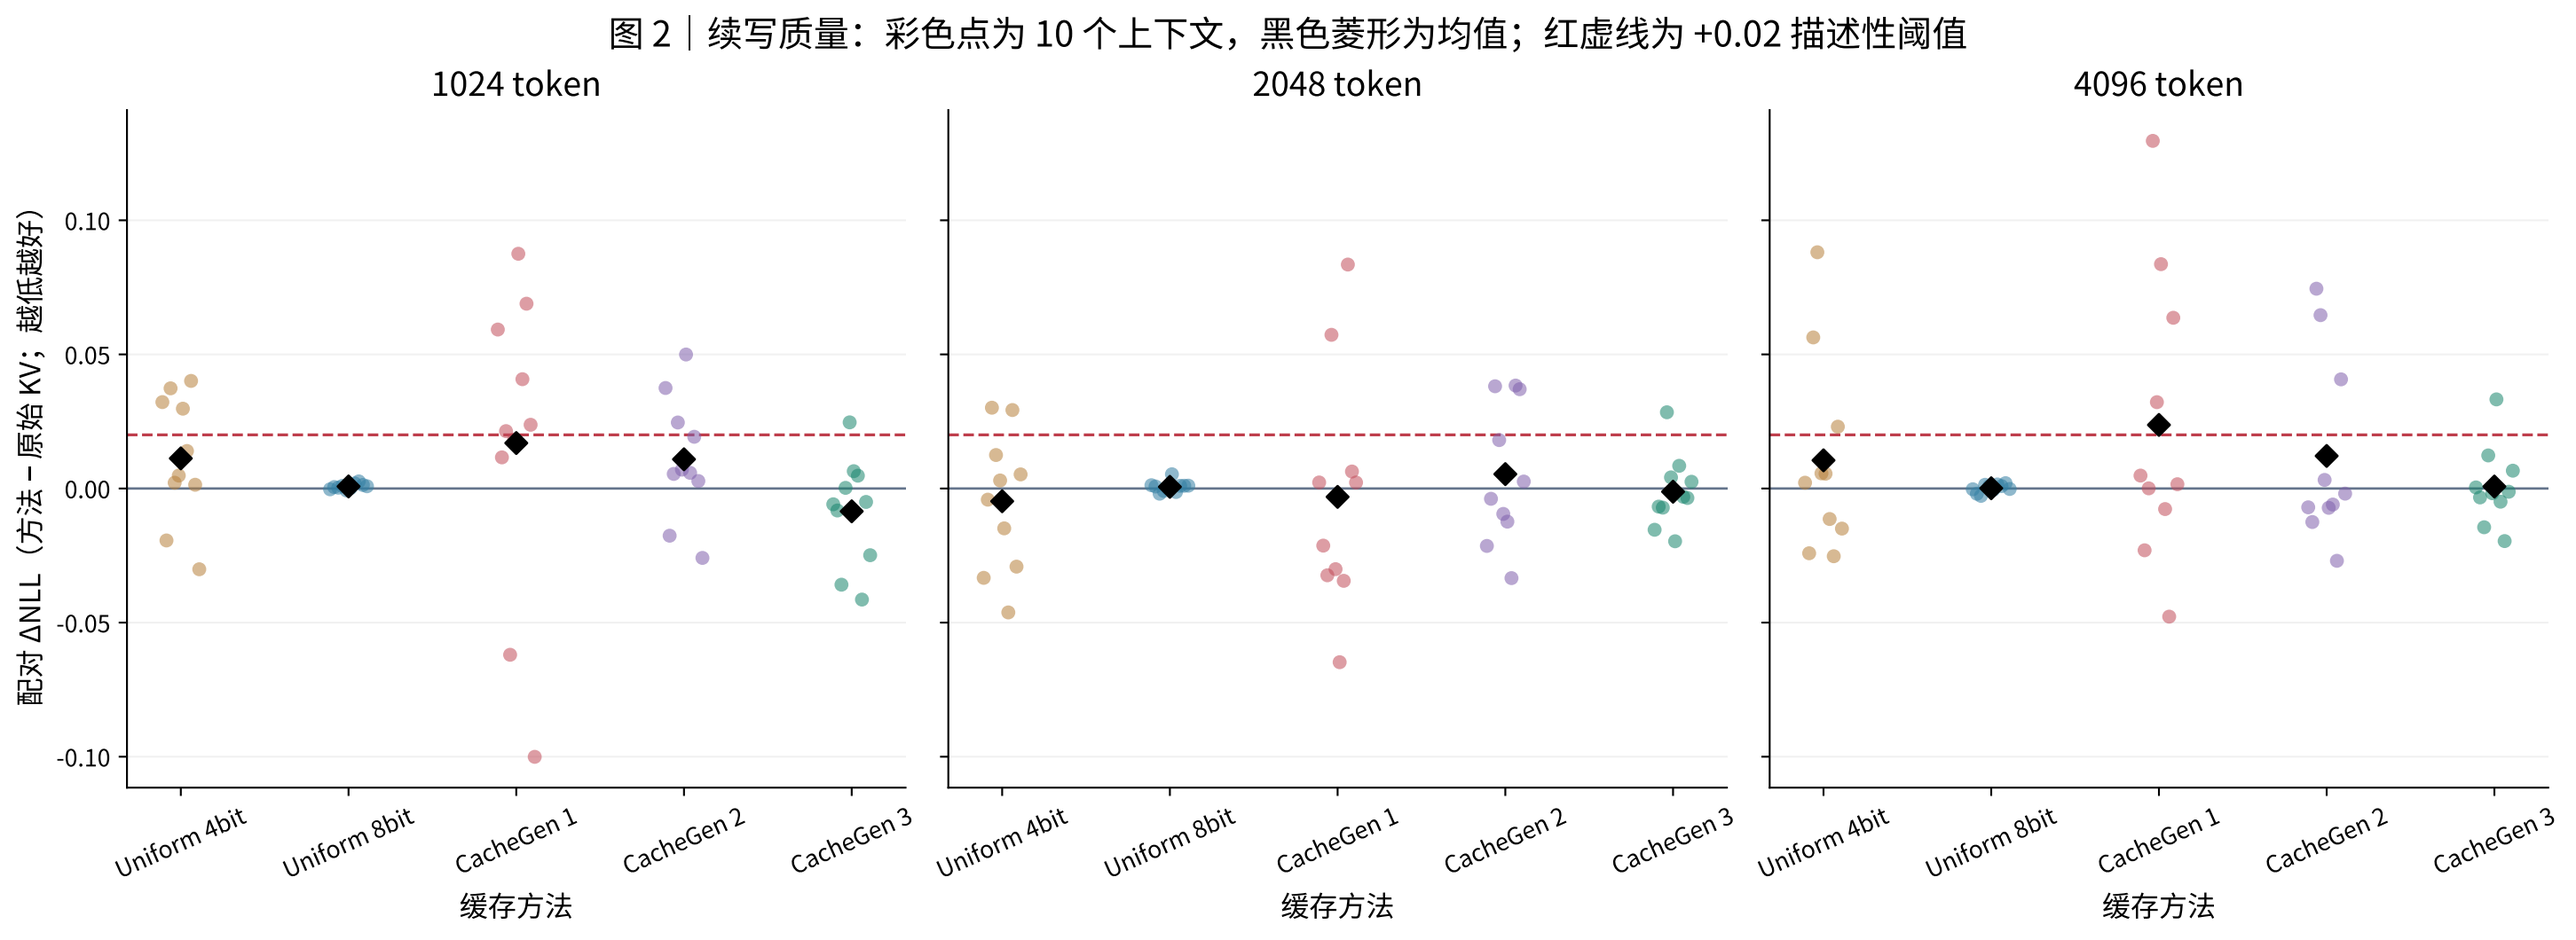
图 2｜续写质量：彩色点为 10 个上下文，黑色菱形为均值；红虚线为 +0.02 描述性阈值
1024 token
2048 token
4096 token
配对 ΔNLL（方法 − 原始 KV；越低越好）
0.10
0.05
0.00
-0.05
-0.10
Uniform 4bit
Uniform 8bit
CacheGen 1
CacheGen 2
CacheGen 3
缓存方法