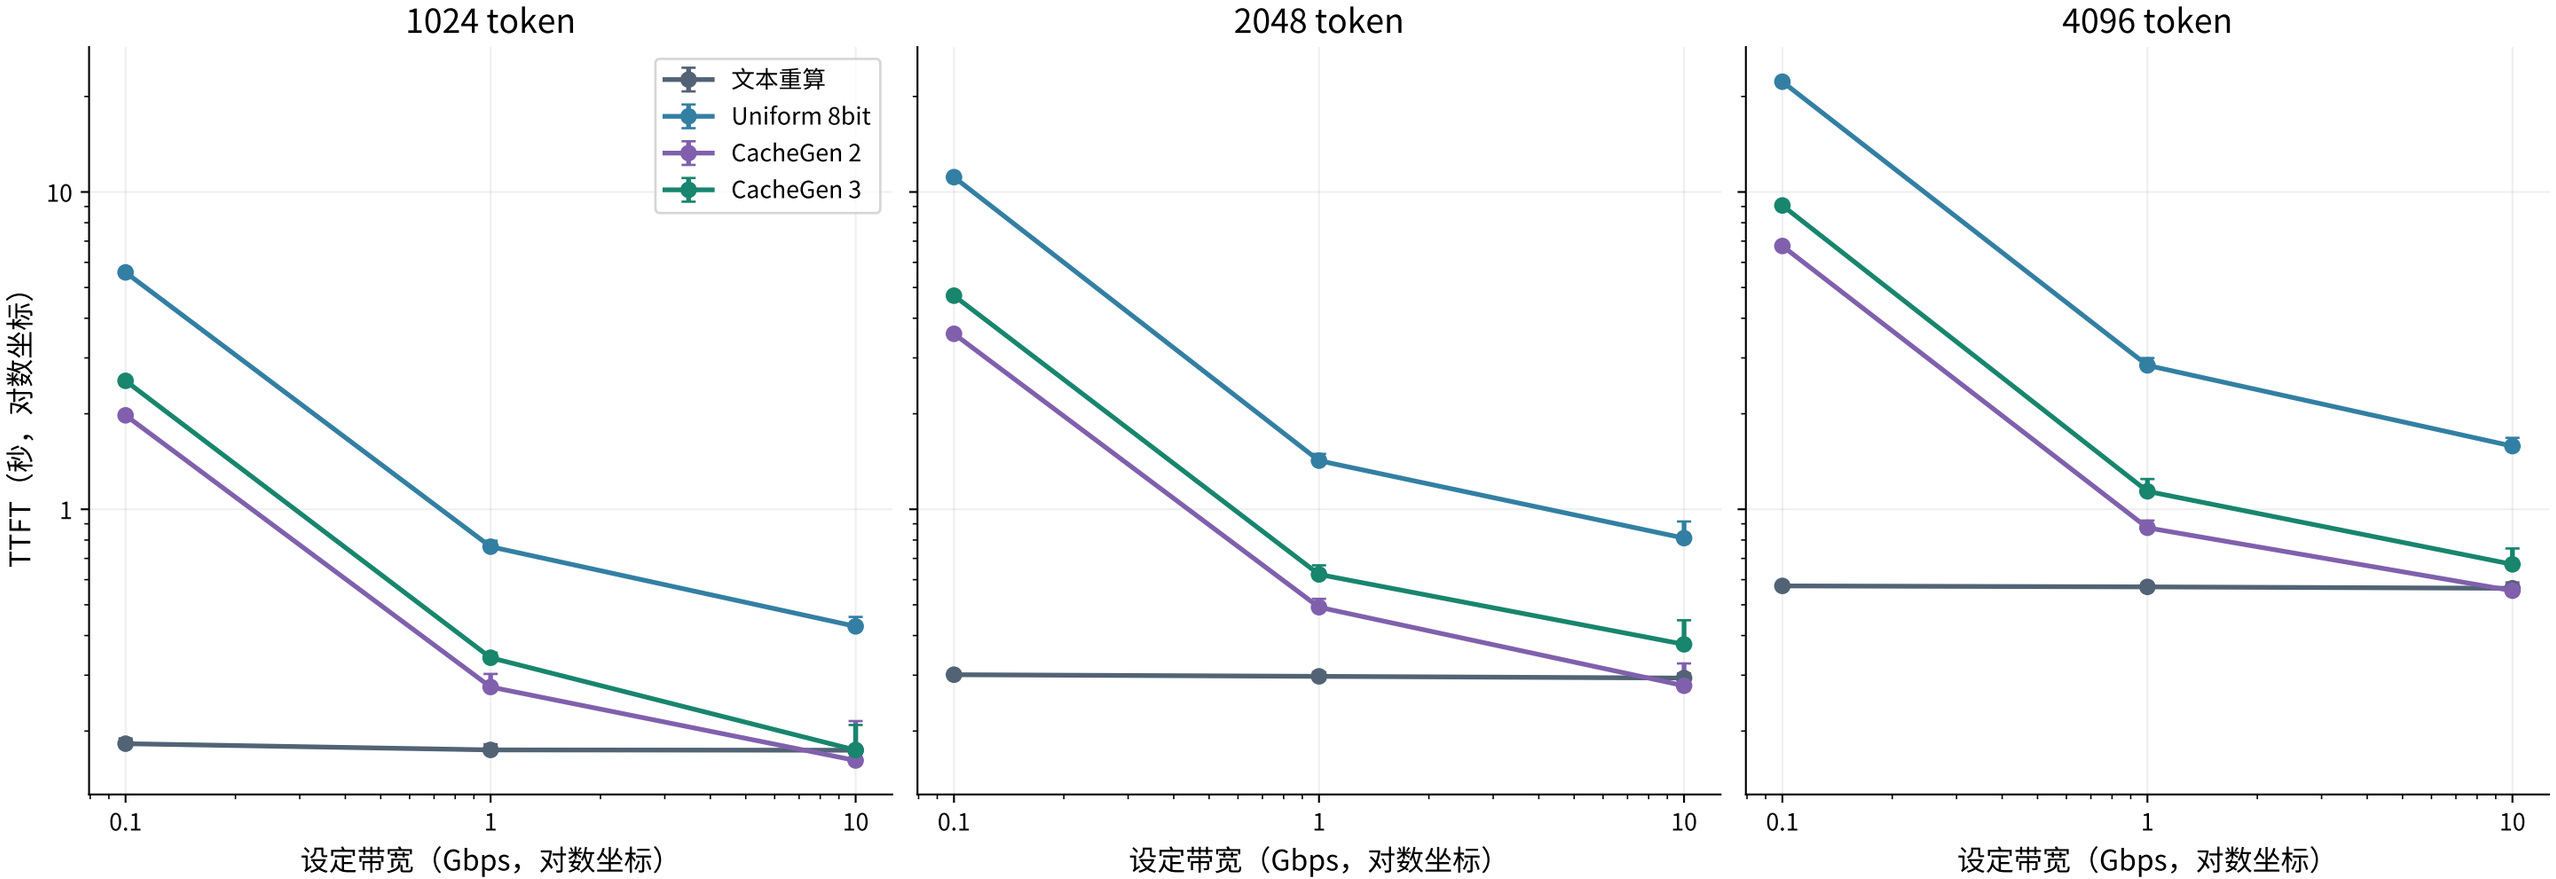图 3｜首 token 延迟：点为中位数，上方短线为 P95；每点 3 个上下文 × 5 次计时