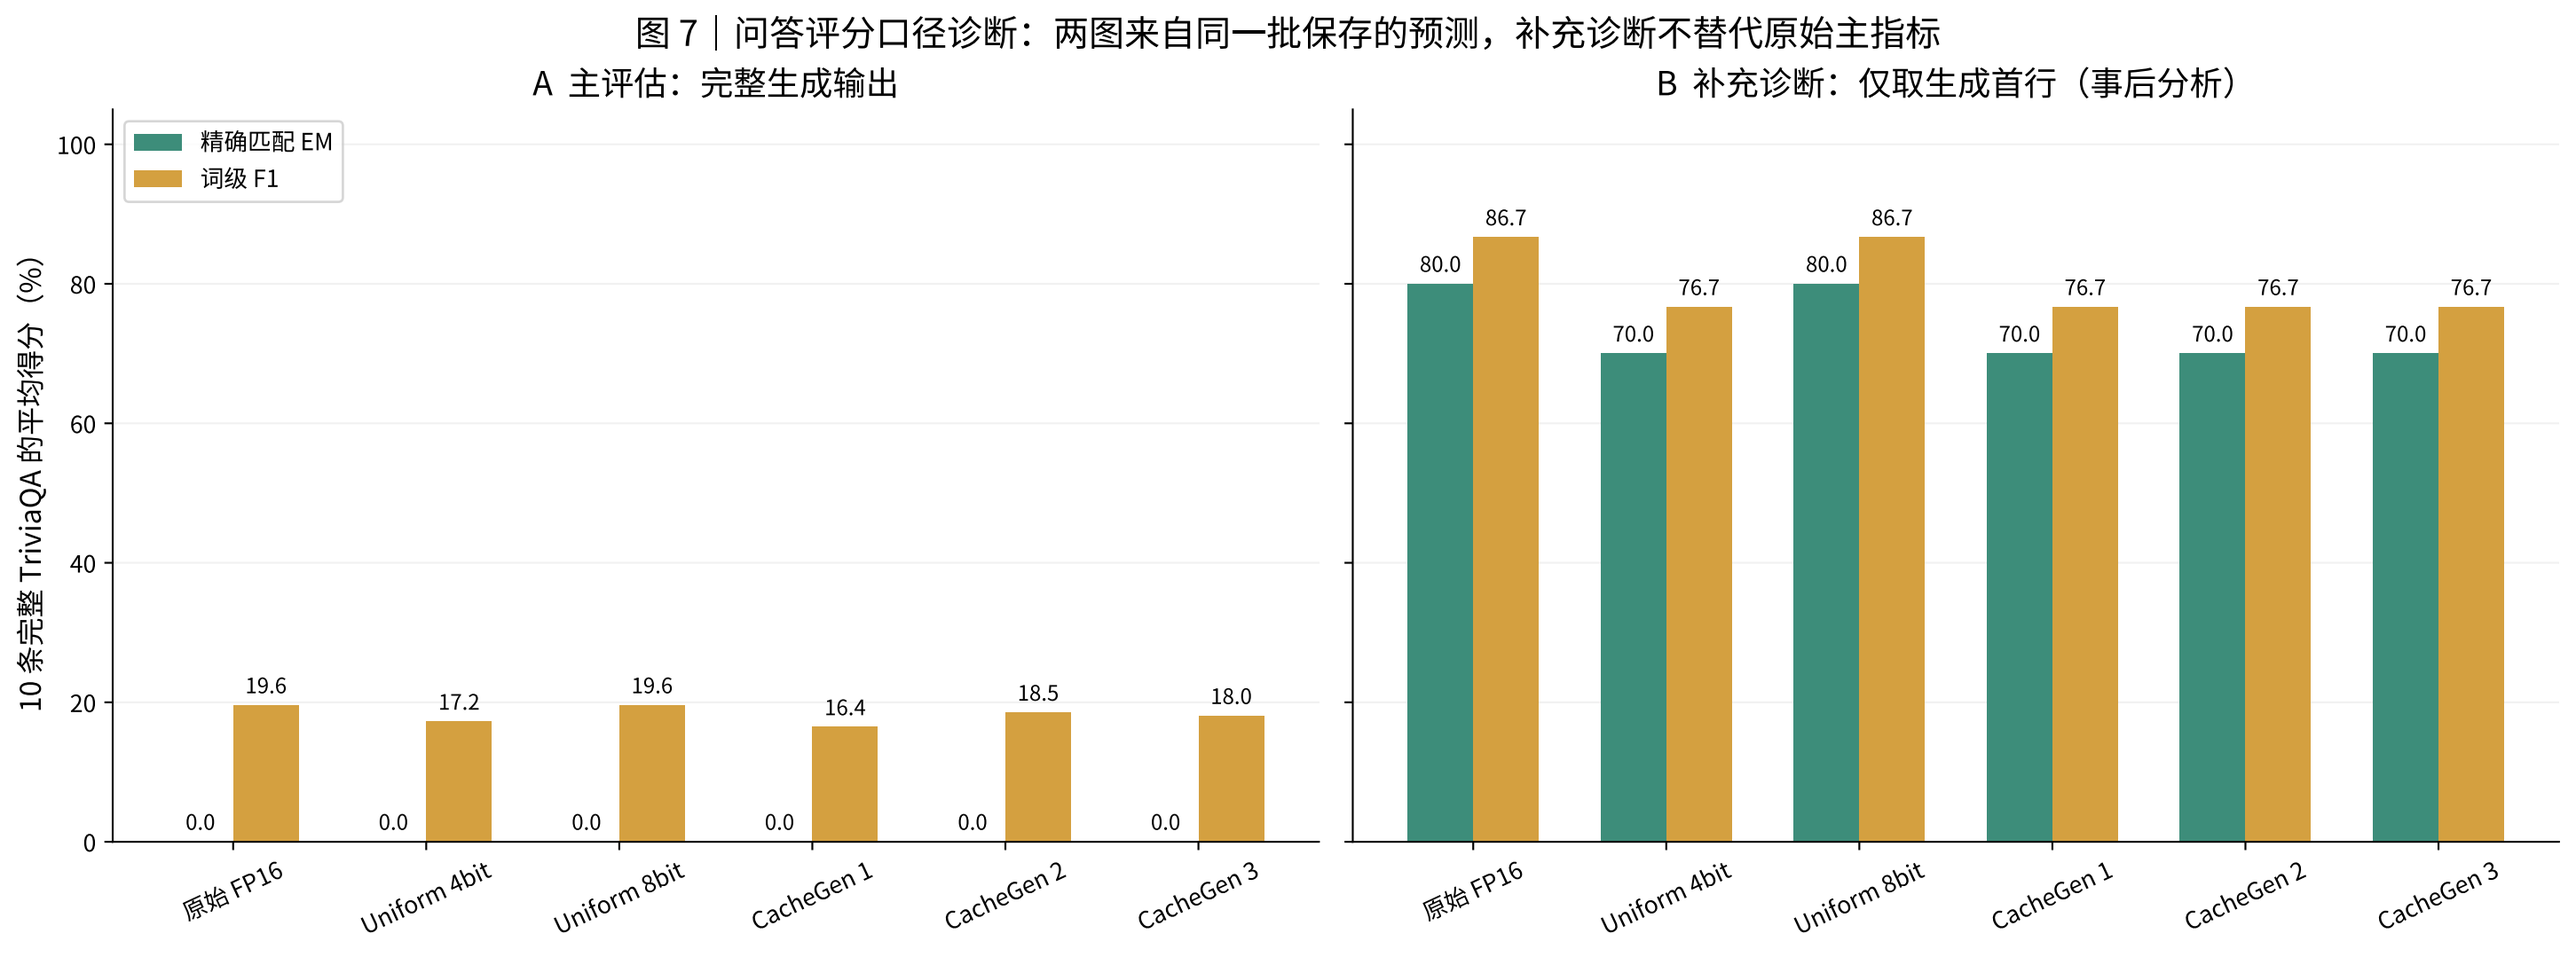
图 7｜问答评分口径诊断：两图来自同一批保存的预测，补充诊断不替代原始主指标
A 主评估：完整生成输出
B 补充诊断：仅取生成首行（事后分析）
精确匹配 EM
词级 F1
10 条完整 TriviaQA 的平均得分（%）
0
20
40
60
80
100
0.0
19.6
0.0
17.2
0.0
19.6
0.0
16.4
0.0
18.5
0.0
18.0
80.0
86.7
70.0
76.7
80.0
86.7
70.0
76.7
70.0
76.7
70.0
76.7
原始 FP16
Uniform 4bit
Uniform 8bit
CacheGen 1
CacheGen 2
CacheGen 3