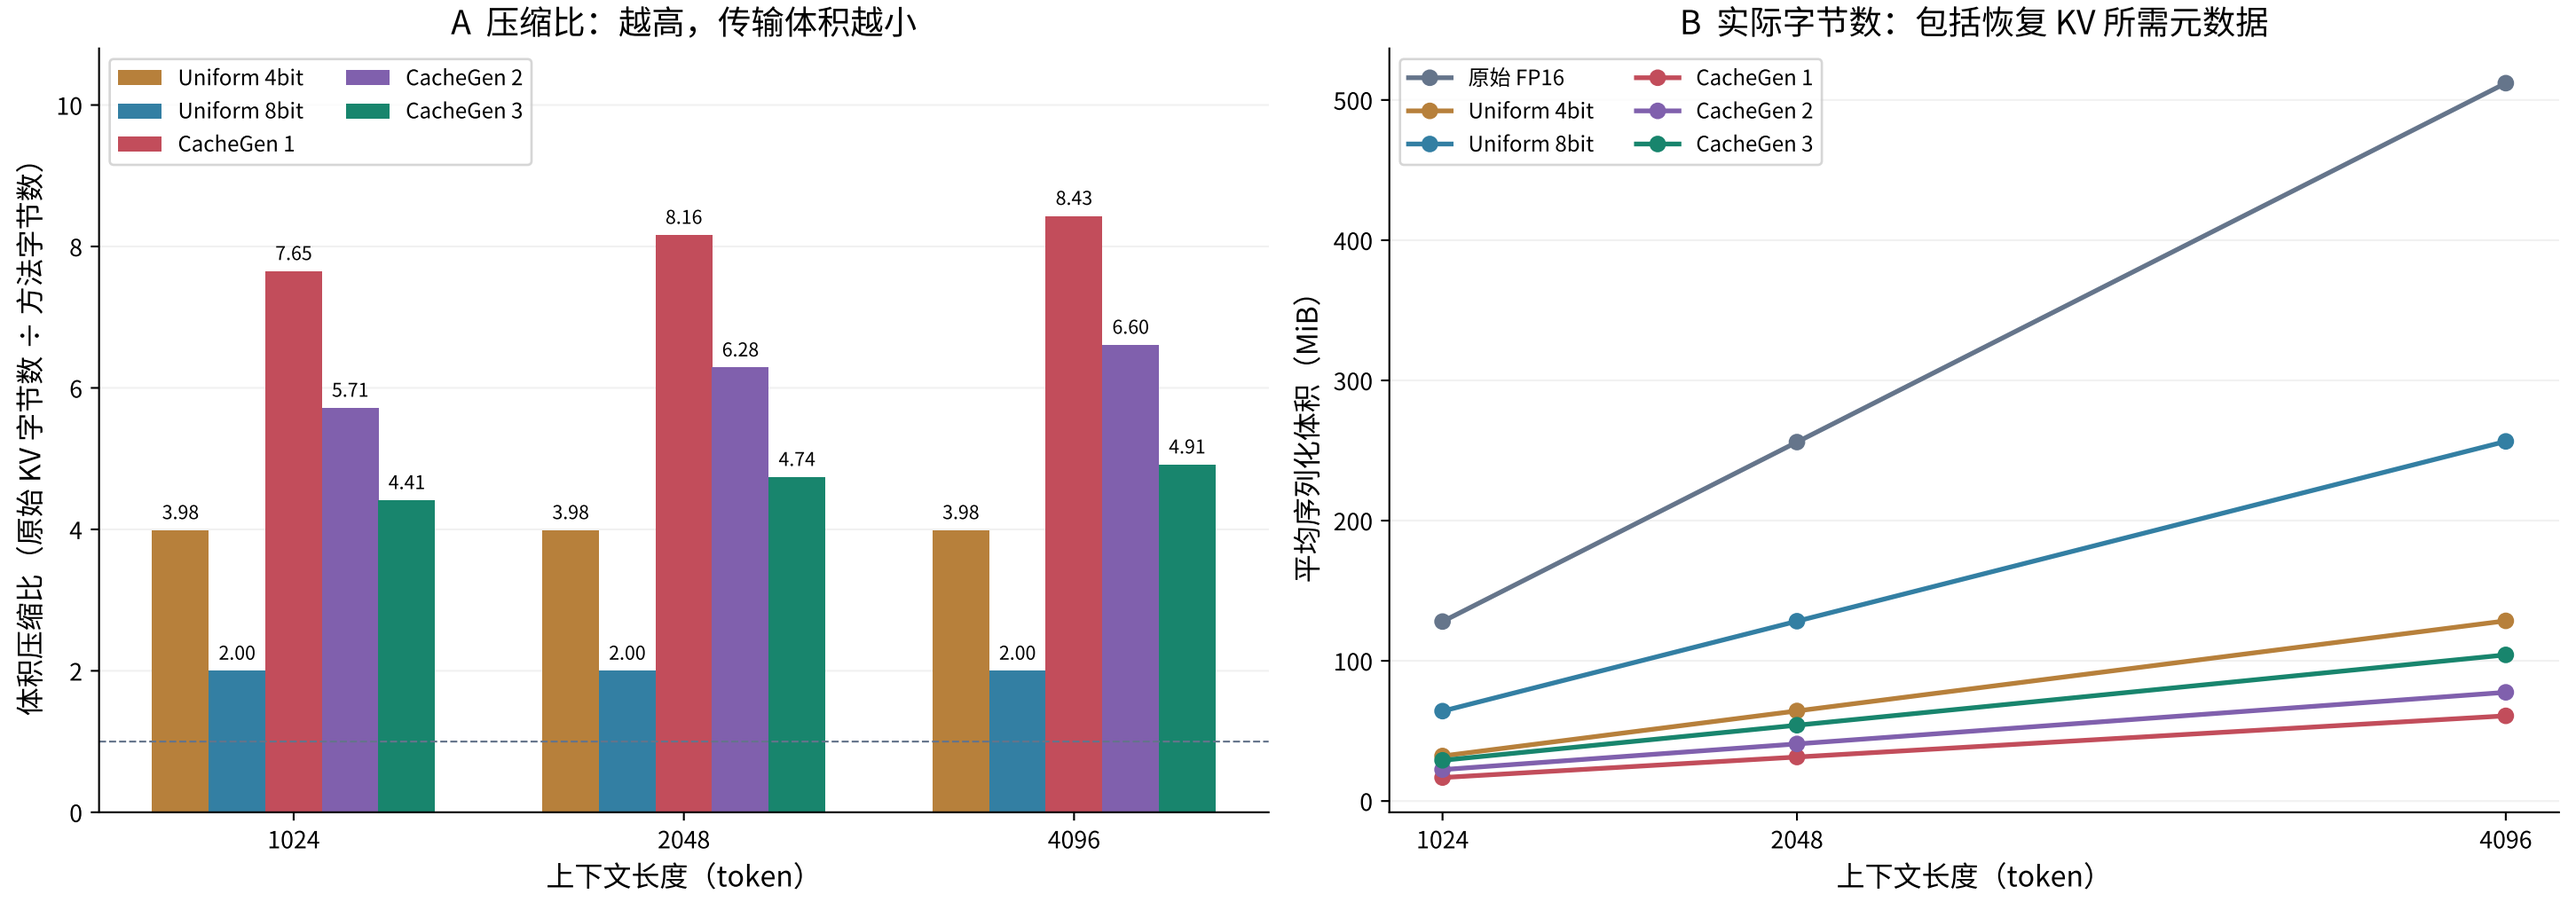
图 1｜压缩收益：10 条源文本 × 3 种长度；所有方法共享 8bit 模型权重



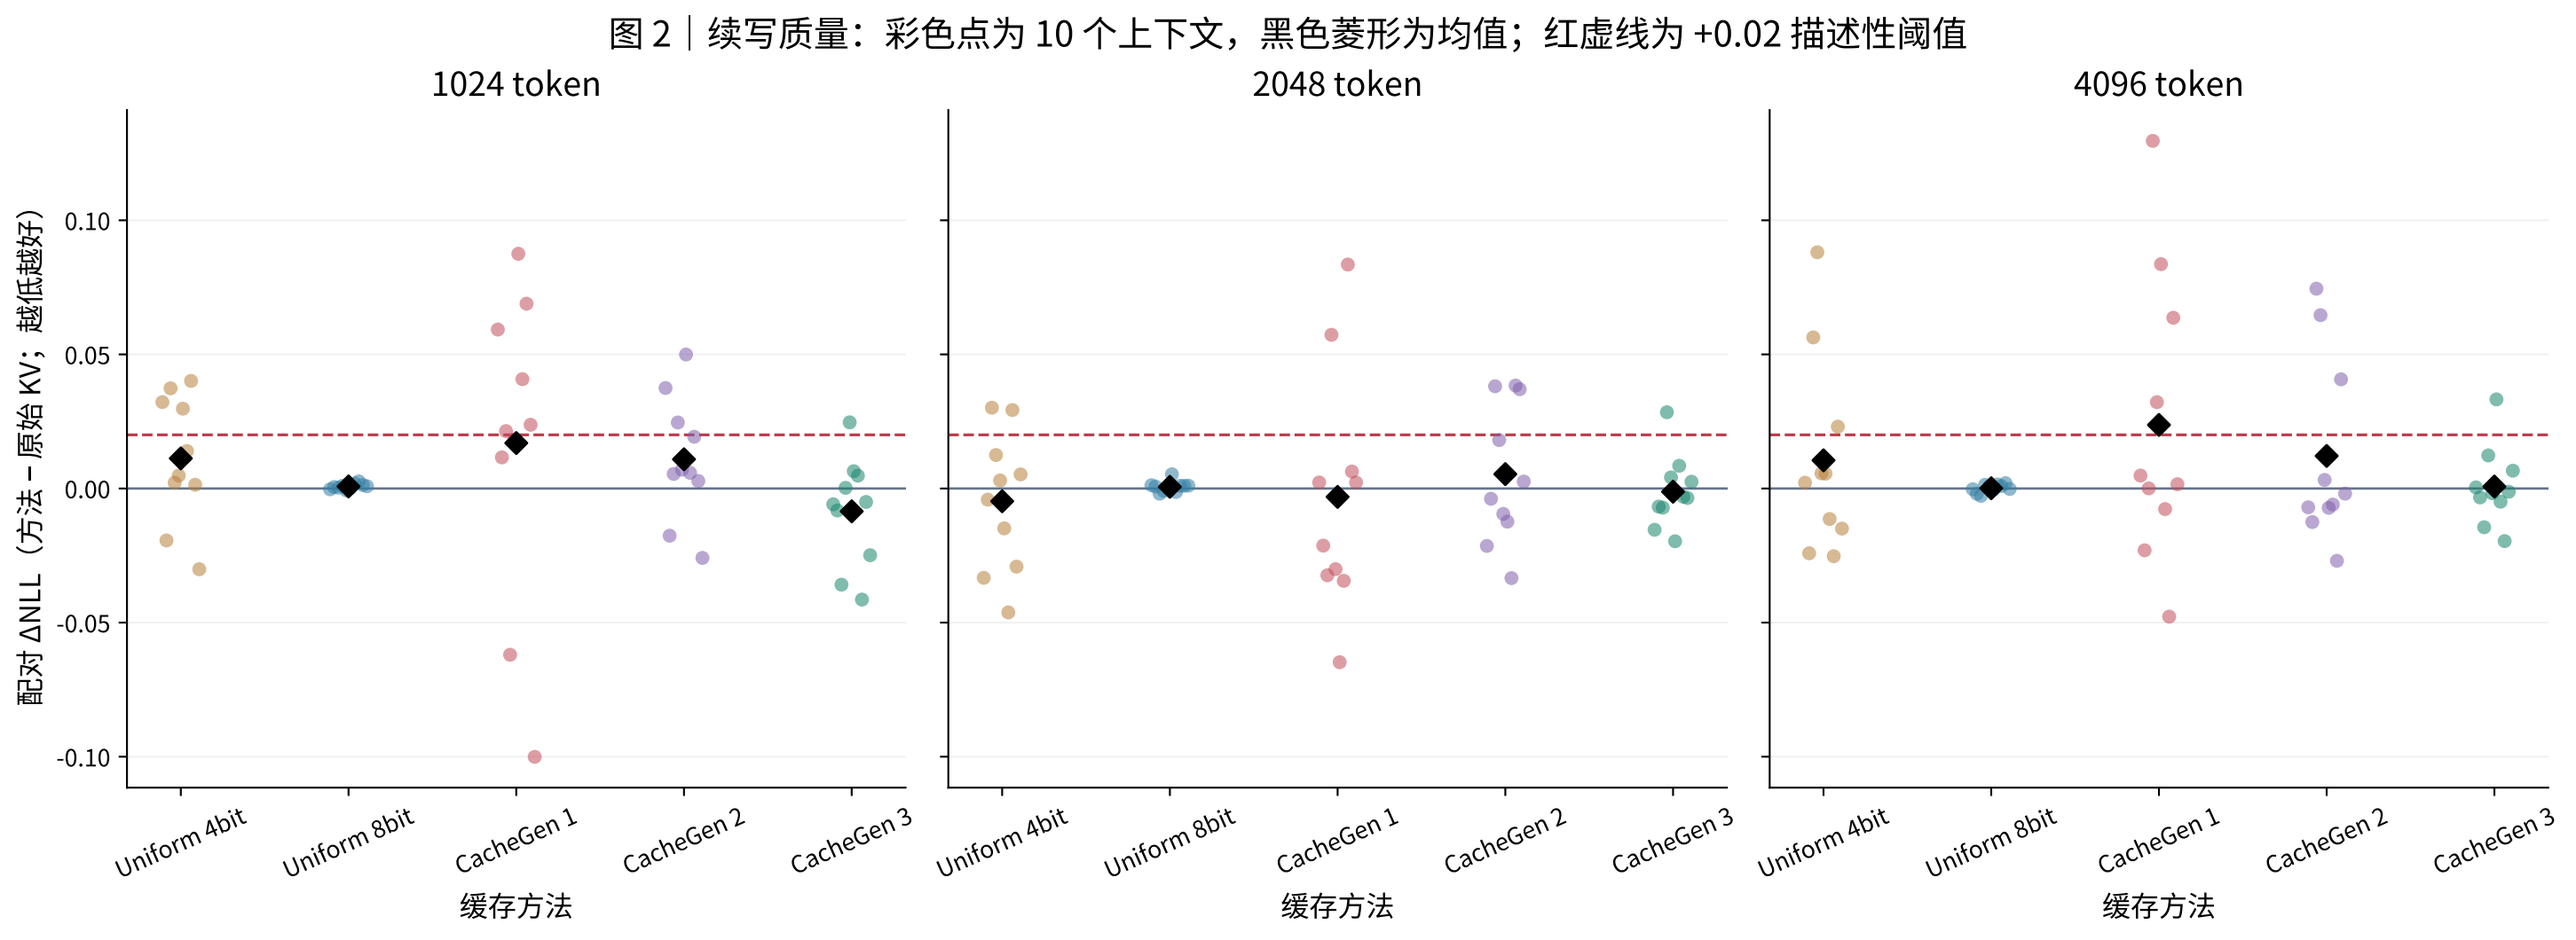

图 2｜续写质量：彩色点为 10 个上下文，黑色菱形为均值；红虚线为 +0.02 描述性阈值
1024 token
2048 token
4096 token
配对 ΔNLL（方法 − 原始 KV；越低越好）
0.10
0.05
0.00
-0.05
-0.10
Uniform 4bit
Uniform 8bit
CacheGen 1
CacheGen 2
CacheGen 3
缓存方法

图 3｜首 token 延迟：点为中位数，上方短线为 P95；每点 3 个上下文 × 5 次计时

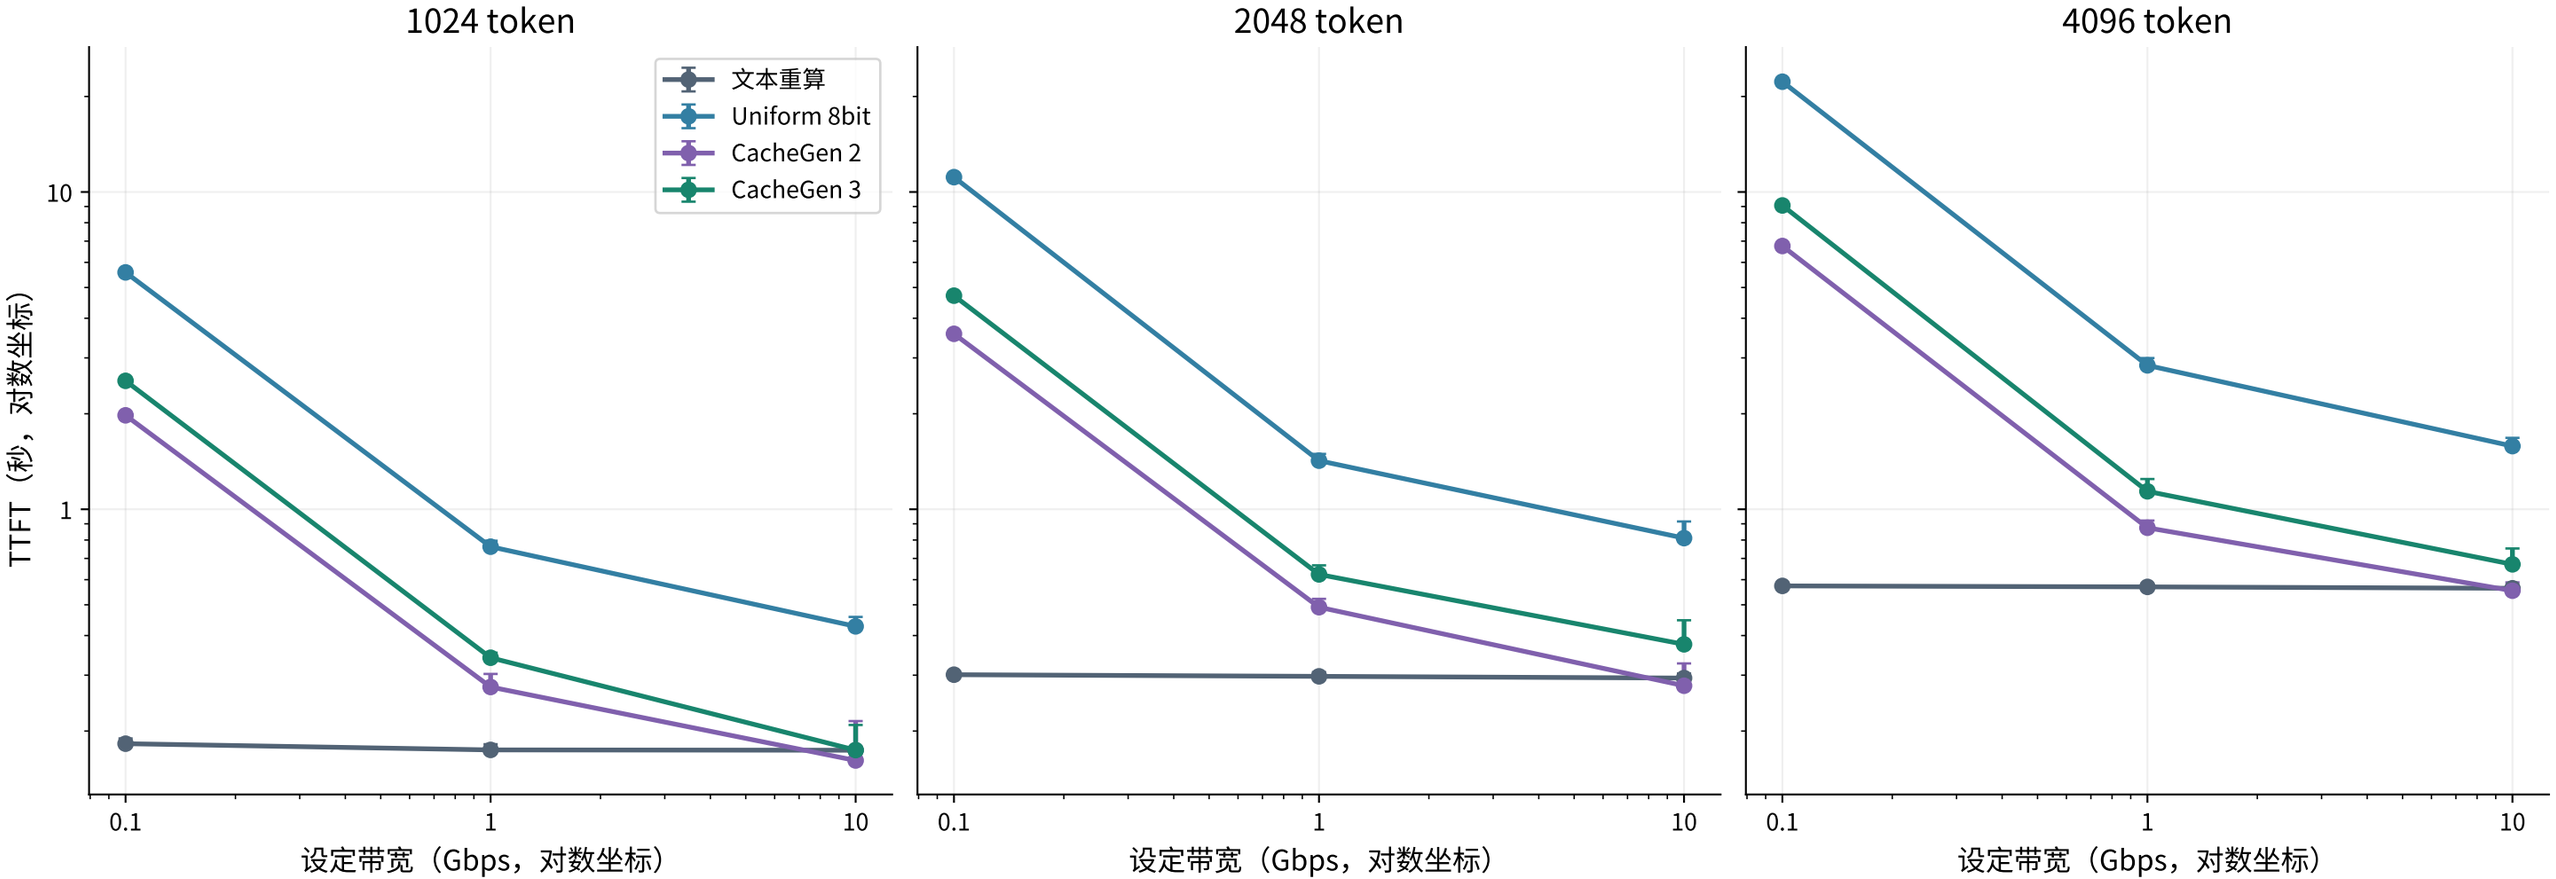


图 4｜相对文本重算的速度比 = 文本 TTFT ÷ 缓存 TTFT
大于 1 表示更快；接近 1 的差异未经显著性检验

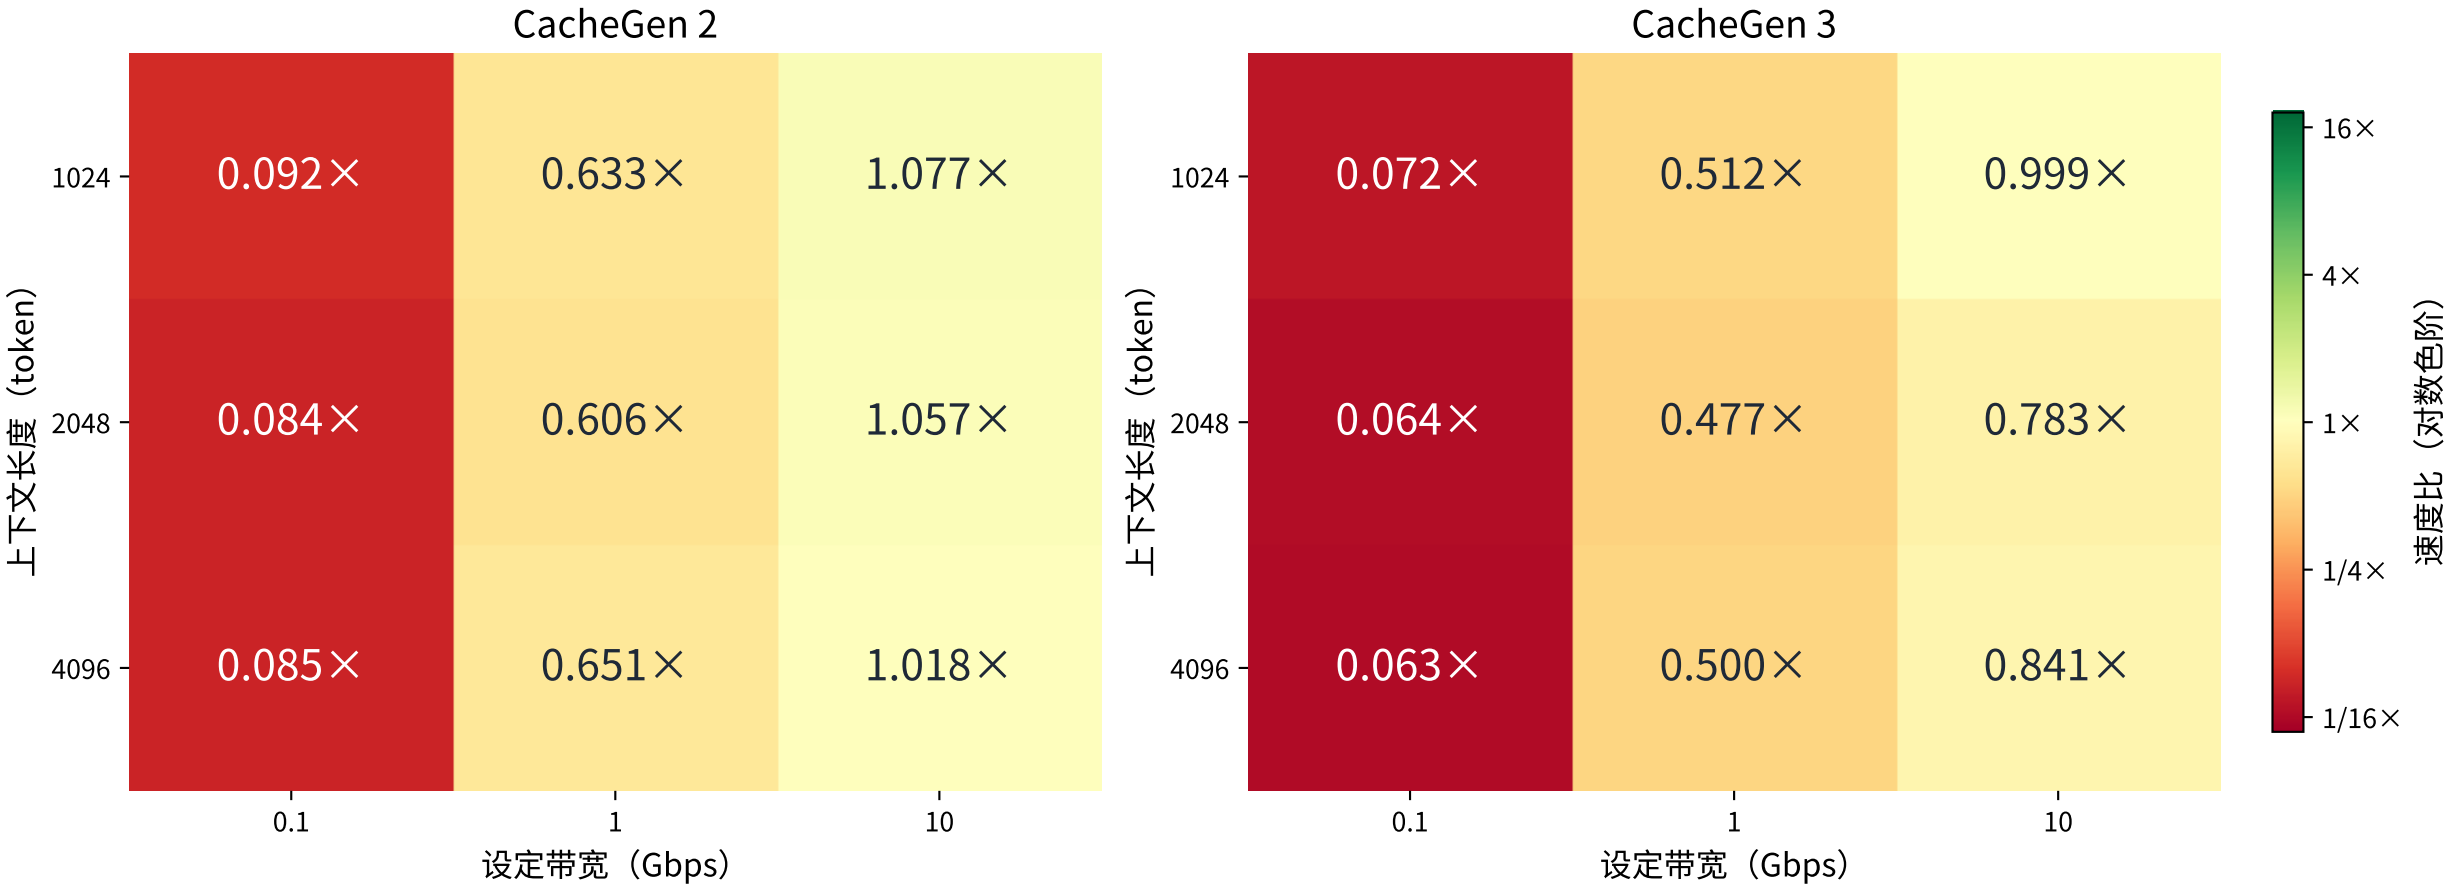


图 5｜4096-token 的 TTFT 均值分解：本机完整接收后再恢复与推理
各面板使用独立纵轴；离线编码耗时不计入 TTFT

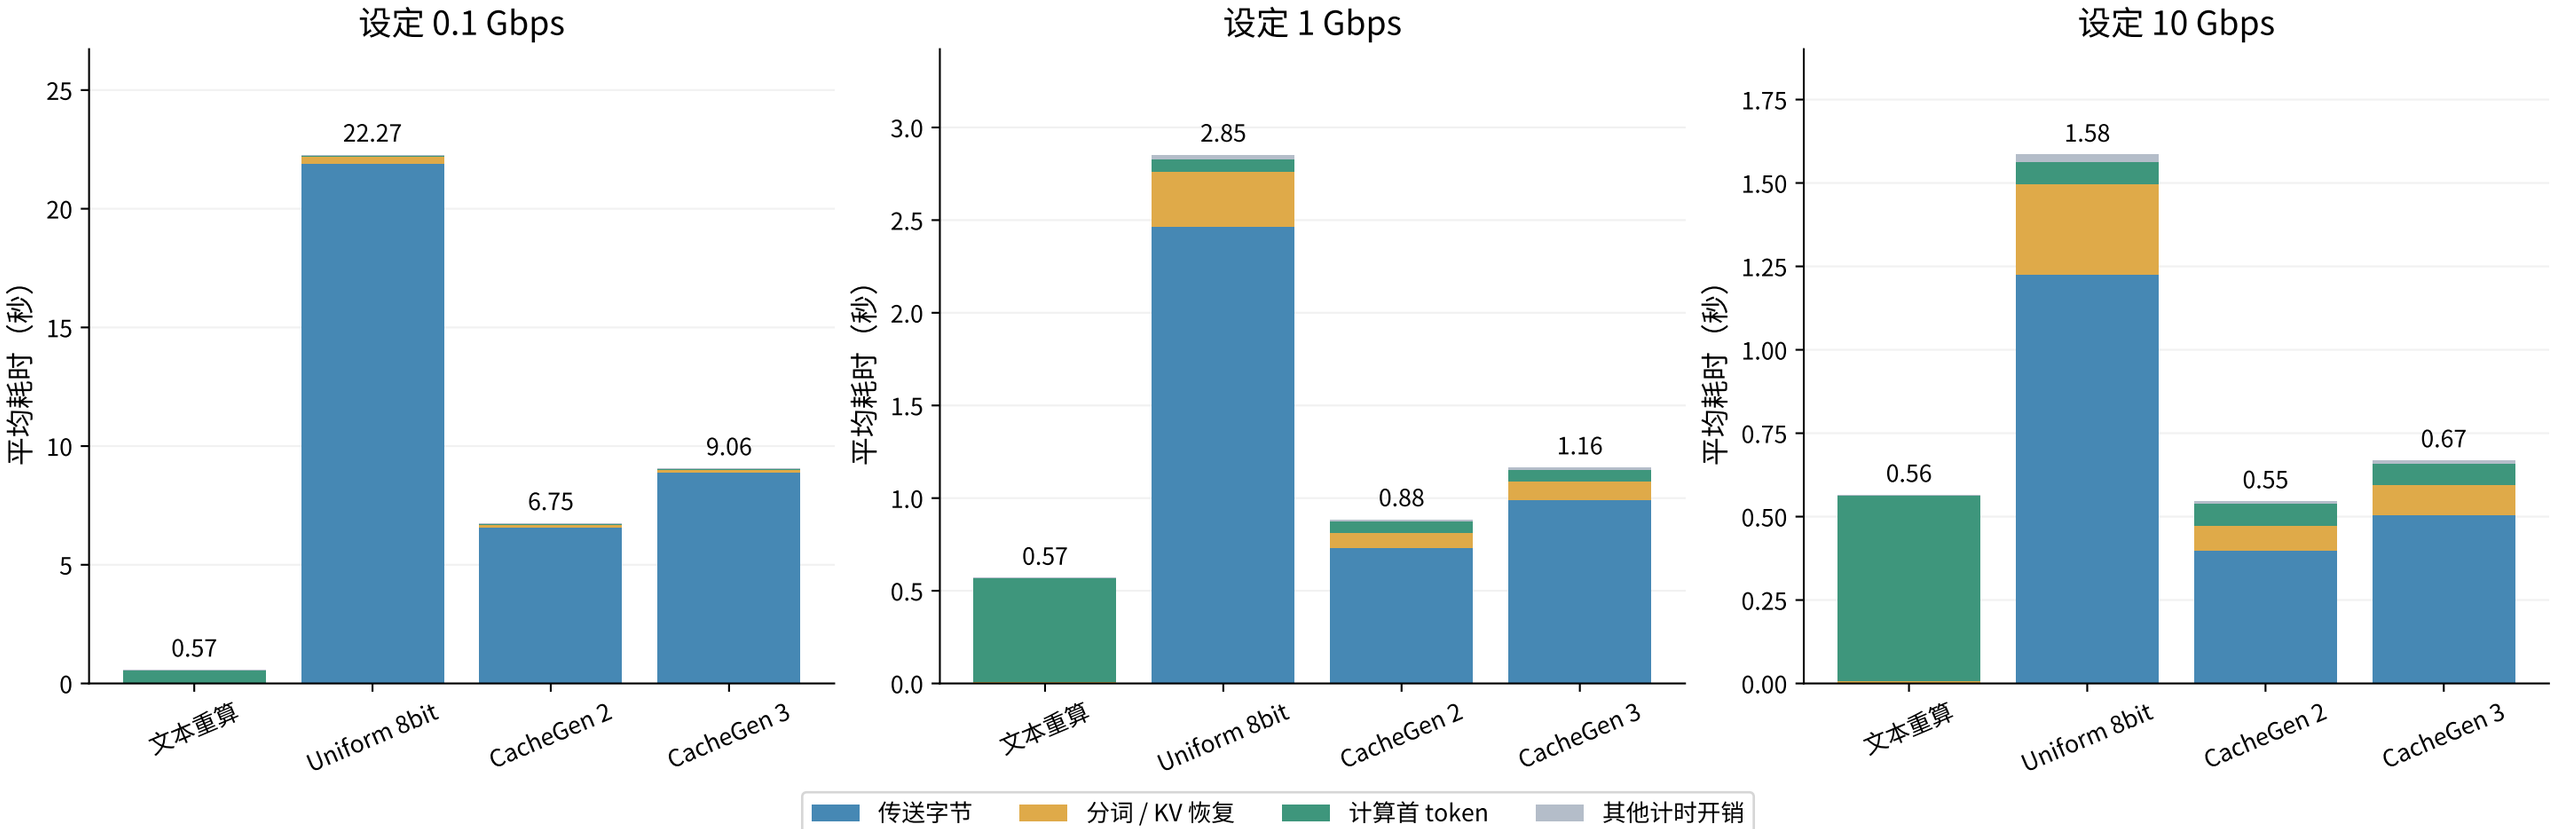
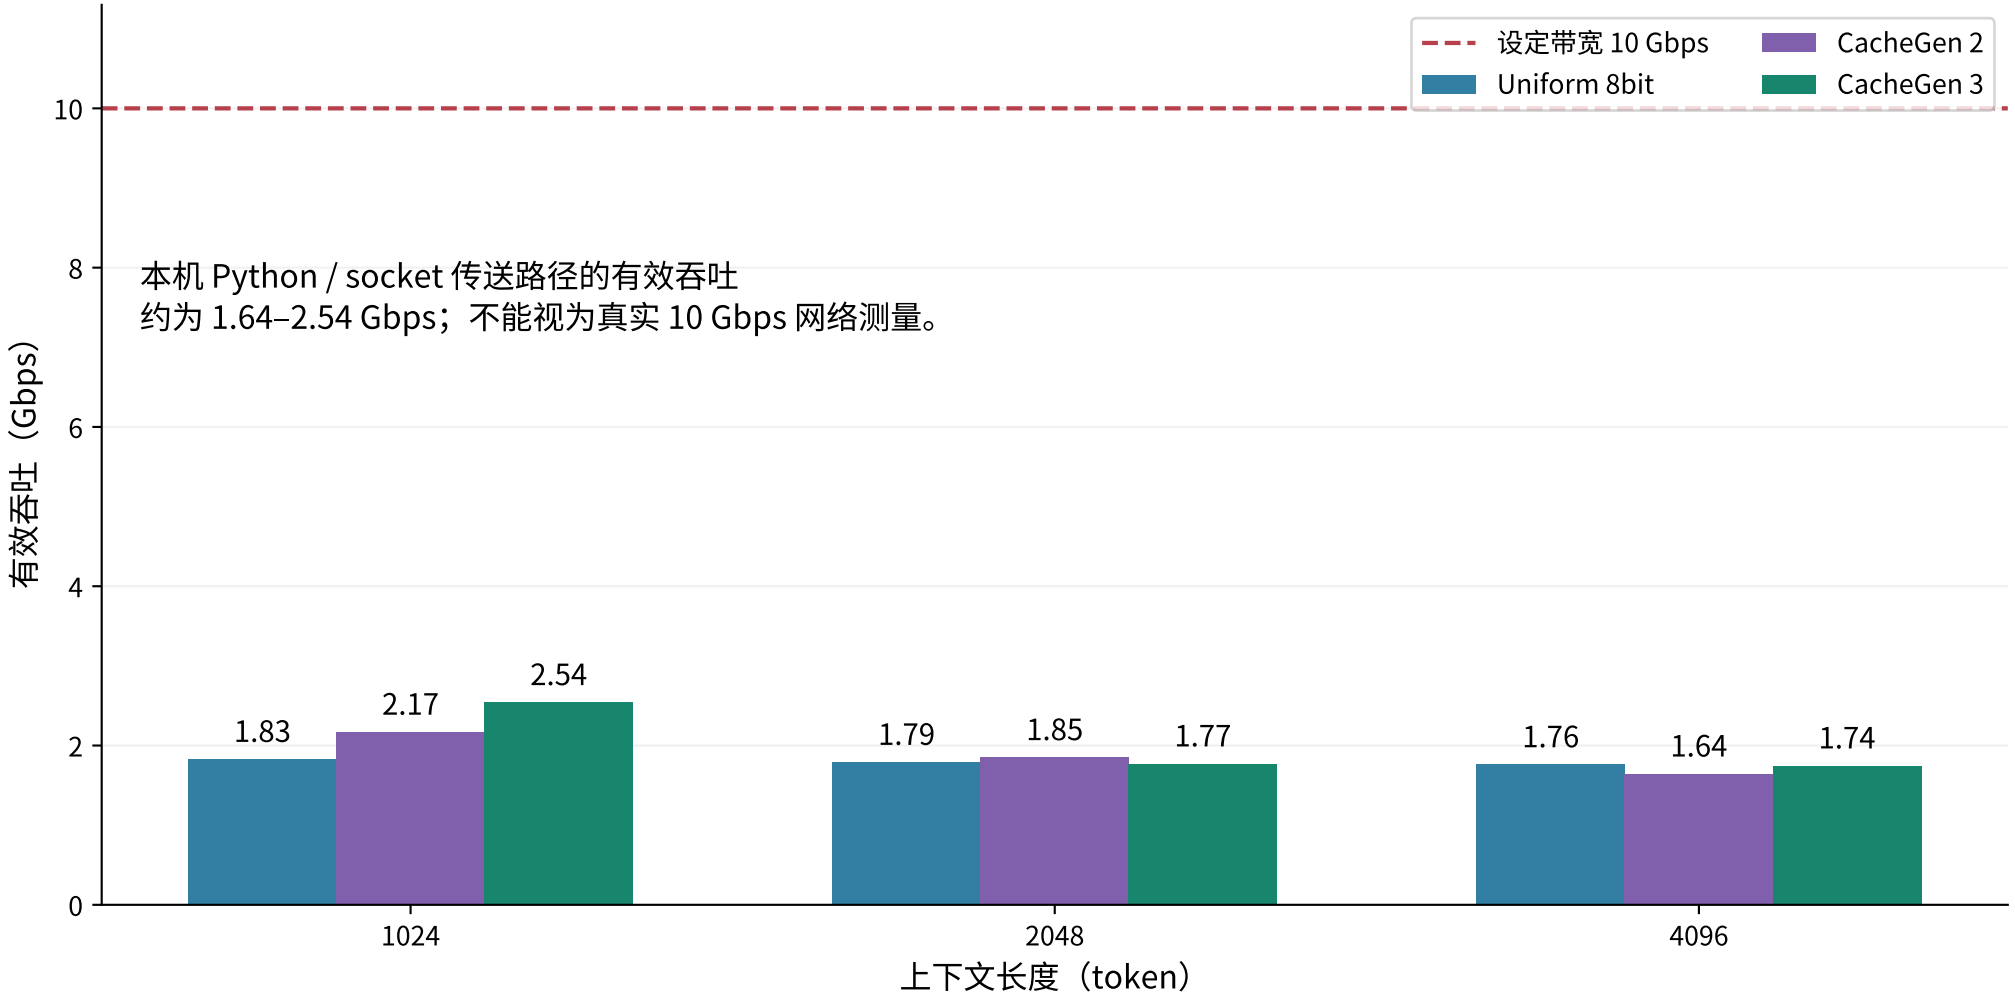
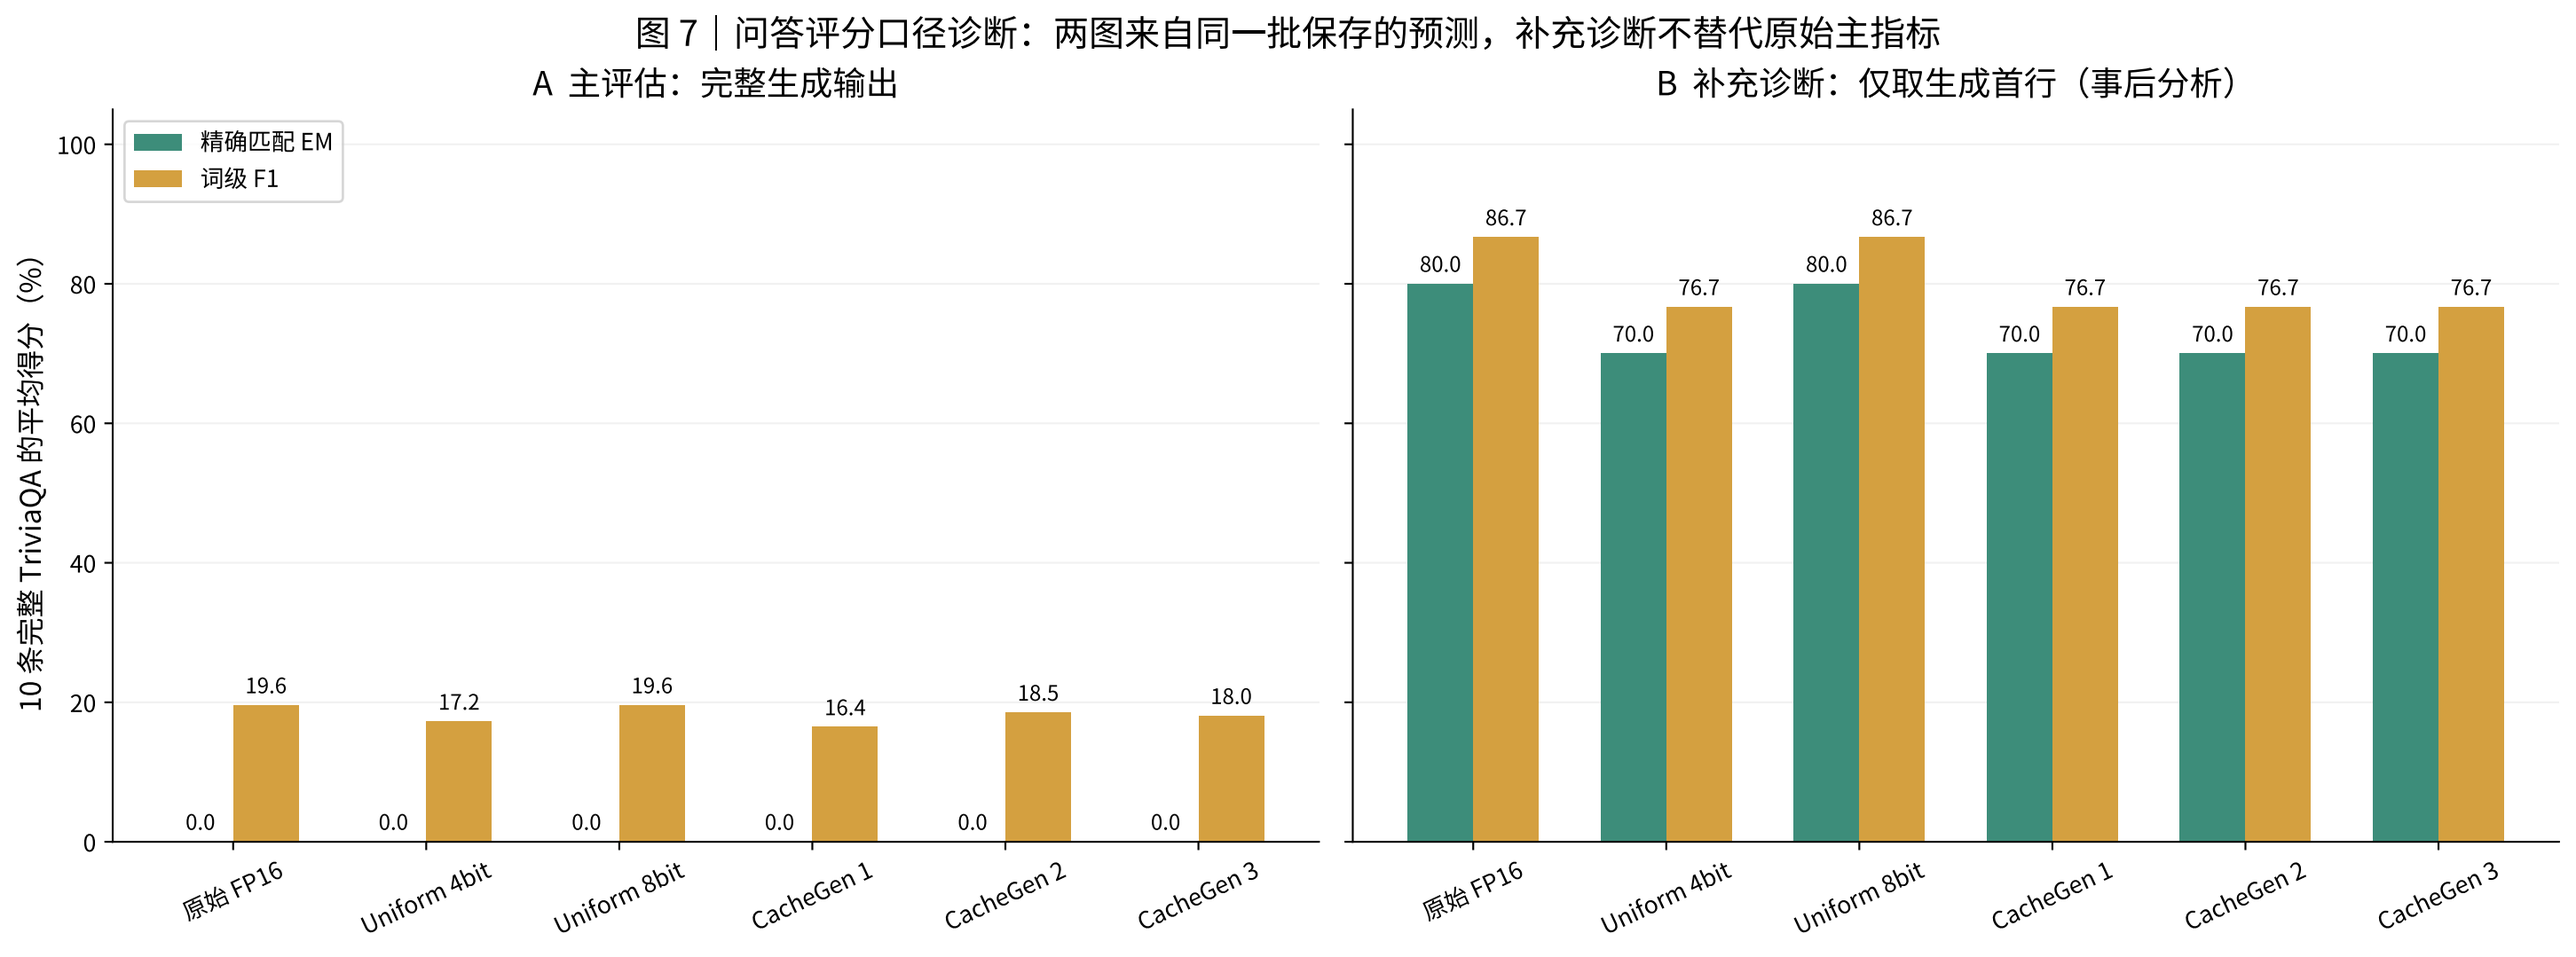


图 6｜设定带宽不等于实际吞吐：10 Gbps 条件下的 KV 传送




图 7｜问答评分口径诊断：两图来自同一批保存的预测，补充诊断不替代原始主指标
A 主评估：完整生成输出
B 补充诊断：仅取生成首行（事后分析）
精确匹配 EM
词级 F1
10 条完整 TriviaQA 的平均得分（%）
0
20
40
60
80
100
0.0
19.6
0.0
17.2
0.0
19.6
0.0
16.4
0.0
18.5
0.0
18.0
80.0
86.7
70.0
76.7
80.0
86.7
70.0
76.7
70.0
76.7
70.0
76.7
原始 FP16
Uniform 4bit
Uniform 8bit
CacheGen 1
CacheGen 2
CacheGen 3